

10 grandes problemas en sistemas de recomendación - 2020

Denis Parra

Profesor Asociado, Depto de Ciencia de la Computación

Escuela de Ingeniería

Pontificia Universidad Católica de Chile & IMFD

Pequeña Biografía

- Profesor Asociado DCC UC, miembro IALab UC, líder del grupo SocVis UC.
- PhD in Information Science and Technology (U. Pittsburgh, 2013)
- Ingeniero Civil en Informática UACh (2004)
- Investigador adjunto del IMFD
- Dicto del curso IIC3633 Sistemas Recomendadores


10 Grandes Problemas en Sistemas de Recomendación



Cristian Riveros

para mí ▼

Problema 1:






Cristian Riveros

para mí ▼

Problema 1: Arreglar Netflix.

Motivación para esta charla

- Cristian Riveros (colega DCC UC) dio una charla a mis alumnos sobre el matemático **David Hilbert**.
- **David Hilbert** presentó el 8 de Agosto de **1900** en un Congreso en París una lista de **10 de los 23 grandes problemas de las matemáticas**, los cuales tuvieron gran influencia durante el siglo XX.



<https://www.simonsfoundation.org/2020/05/06/hilberts-problems-23-and-math/>

Motivación para esta charla II

- El ACM Webinar de Prof. Joe Konstan
"Recommender Systems: Beyond Machine Learning," presentado a fines del año pasado
<https://learning.acm.org/techtalks/recommendersystems>

Motivación para esta charla III

- Agradecimientos a los siguientes amigos-investigadores por sus comentarios y discusión por mail :
 - Joe Konstan, University of Minnesota, MI, EEUU
 - Leandro Balby Marinho, UFCG, Brasil
 - Tao Ye, Amazon (former Pandora), EEUU
 - Bart Knijnenburg, Clemson University, SC, EEUU
 - Marko Tkalčič, U. Primorska, Slovenia
 - Rodrygo Santos, UFMG, Brasil
 - Pablo Castells, UAM, España
 - Soledad Pera, Boise State University, ID, EEUU
 - Christoph Trattner, University of Bergen, Noruega

Contenidos

- Introducción a los sistemas de recomendación
- 10 problemas de los sistemas de recomendación

*



Sistemas Recomendadores

INTRODUCCION

* Danboard (Danbo): Amazon's cardboard robot, in these slides it represents a recommender system

¿Por qué son importantes los RecSys?

- Se han vuelto populares por la variedad de aplicaciones en que la gente toma decisiones frente a una gran cantidad de ítems.

NETFLIX


Spotify

YouTube



Definición RecSys

Sistemas que ayudan a (grupos de) personas a encontrar ítems relevantes en un espacio repleto de ítems o información.



(MacNee et al. 2006)

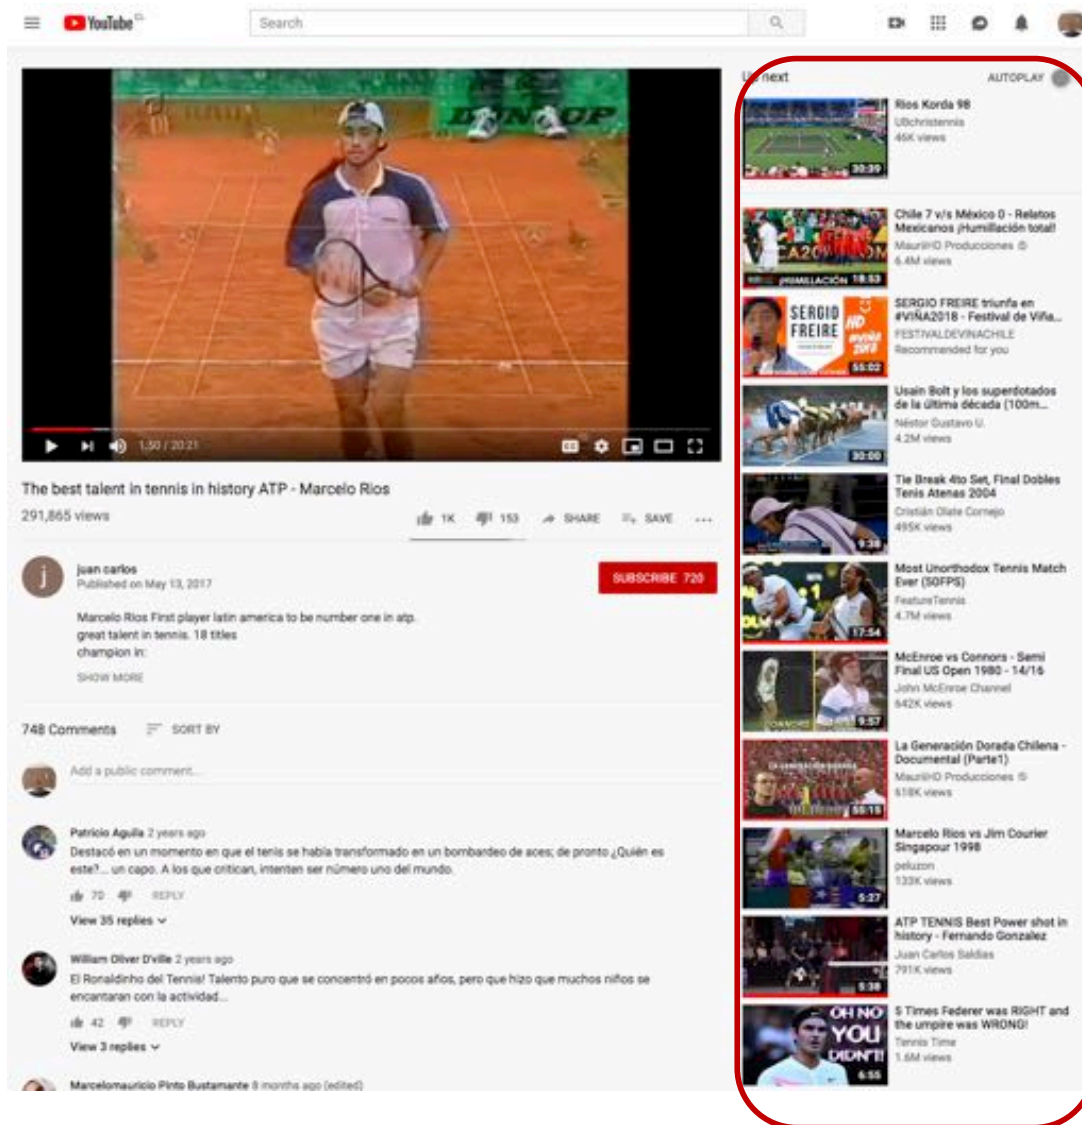
Definición RecSys II

- Konstan presenta a los sistemas de recomendación de forma más genérica: *herramientas que ayudan a reducir lo que de otra forma sería una cantidad de elecciones abrumadora*
 - *Filtros (spam filter, selection or removal of items)*
 - *Recomendaciones (listas top-N)*
 - *Predicción de valores (estrellas de hoteles, restaurantes, etc.)*

Konstan 2020

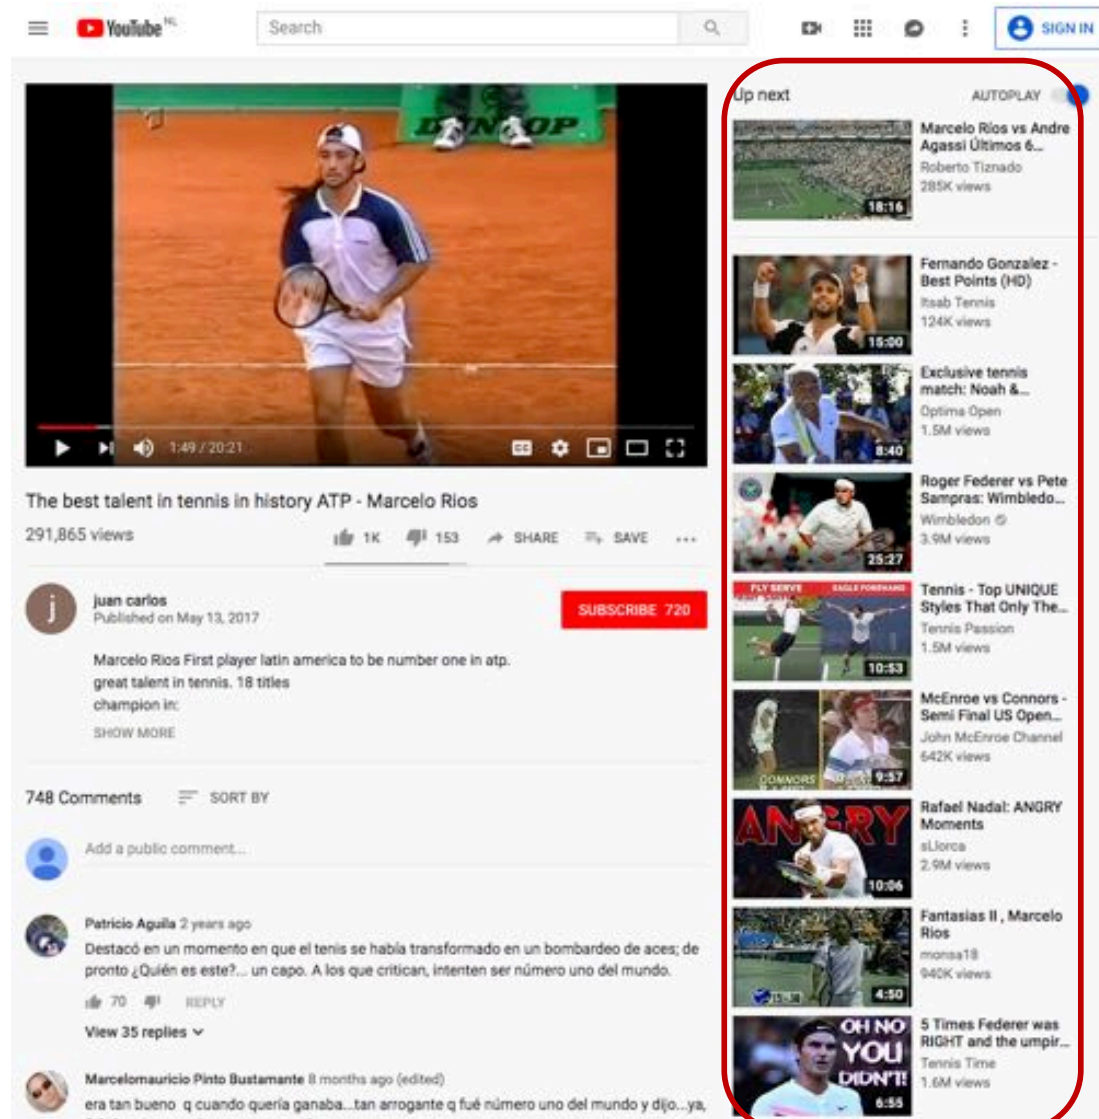
¿ Cómo se presentan las recomendaciones ?

En YouTube



- Lista de videos recomendados

En YouTube - Personalización

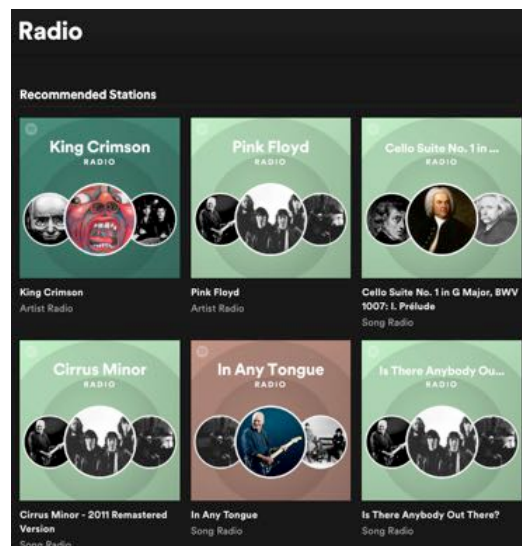
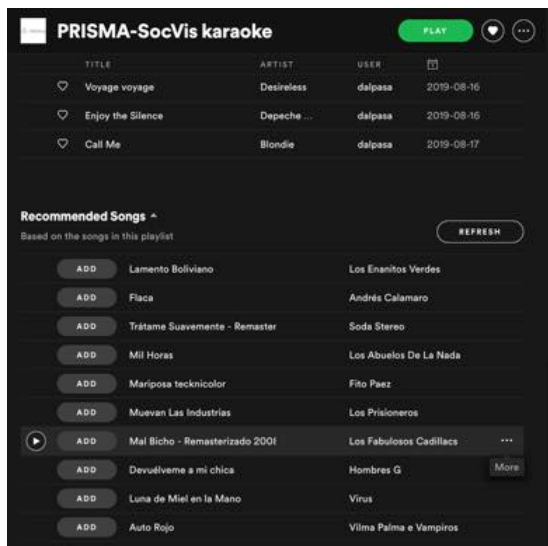
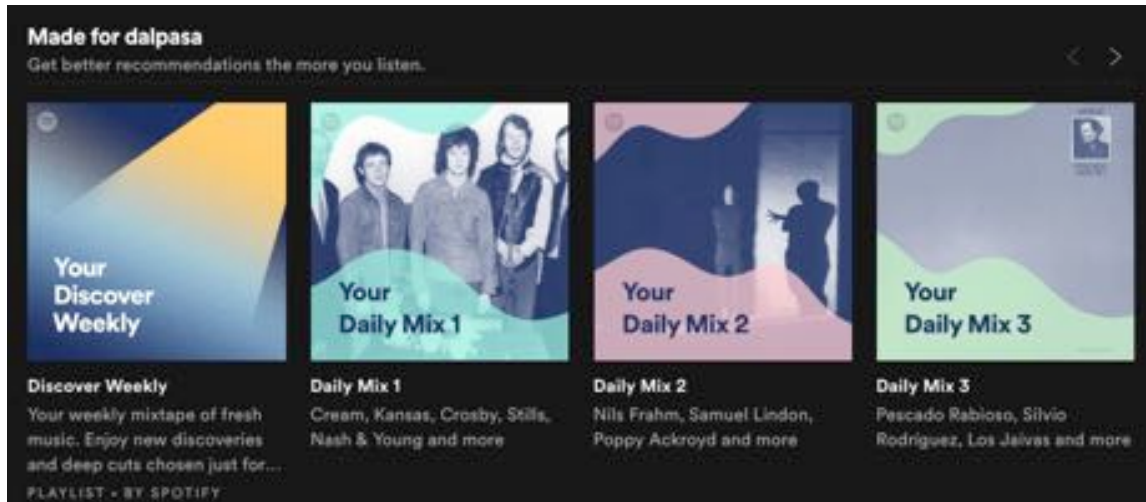


Si abro el mismo video desde otra cuenta o país, aparecen otras recomendaciones (distintos niveles de contextualización y personalización)

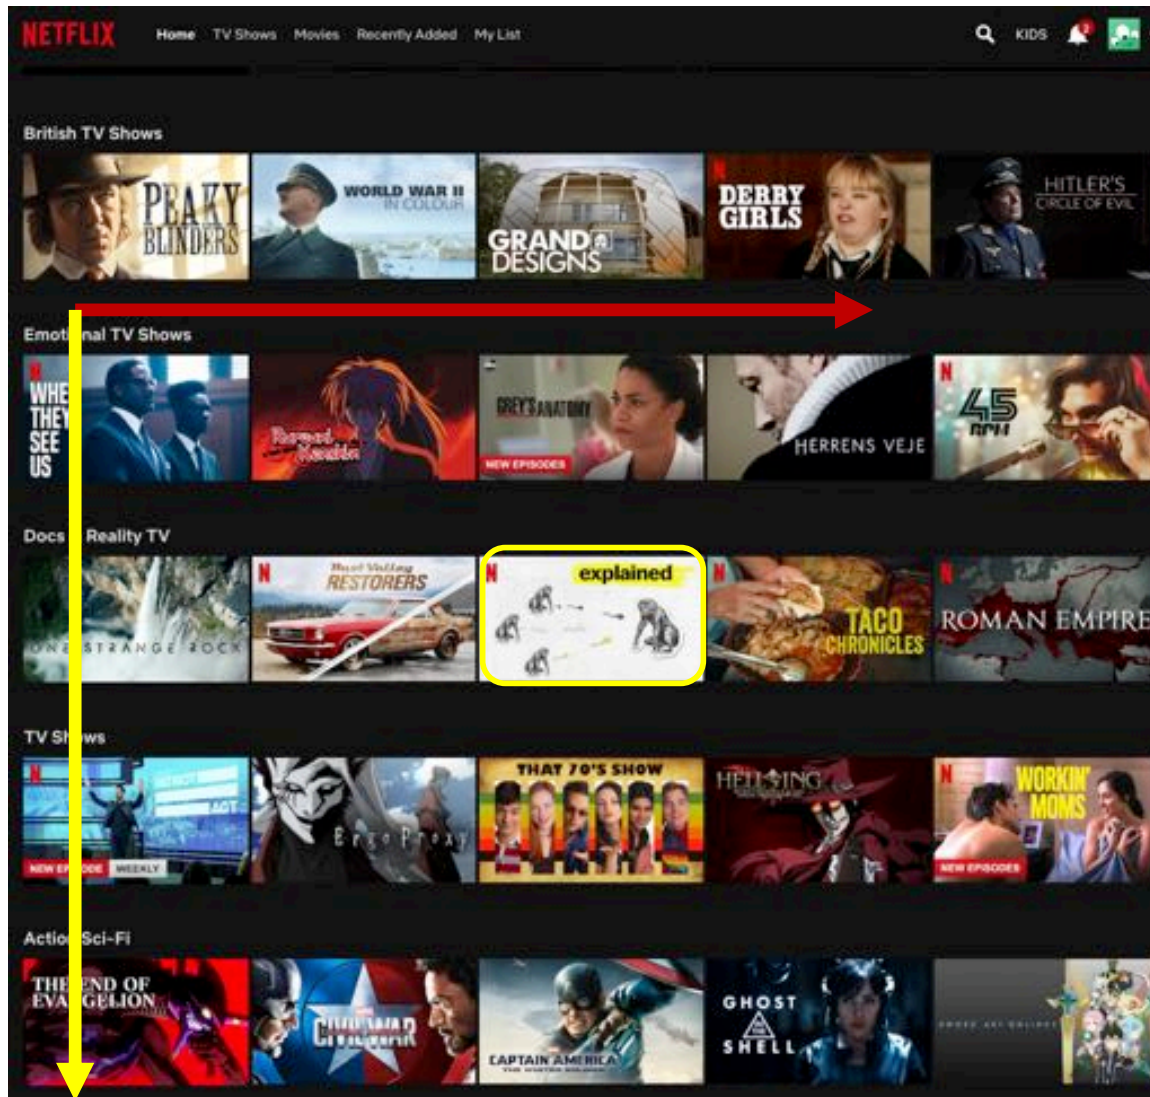
En Spotify

Varios tipos de recomendaciones:

- Listas de canciones
- Canciones para continuar listas
- Estaciones de Radio



En Netflix




- Listas de películas y series
- El orden en que se presentan estas listas
- La imagen de “cover” para presentar una serie o película

**¿ Cuáles son los principals
métodos ?**

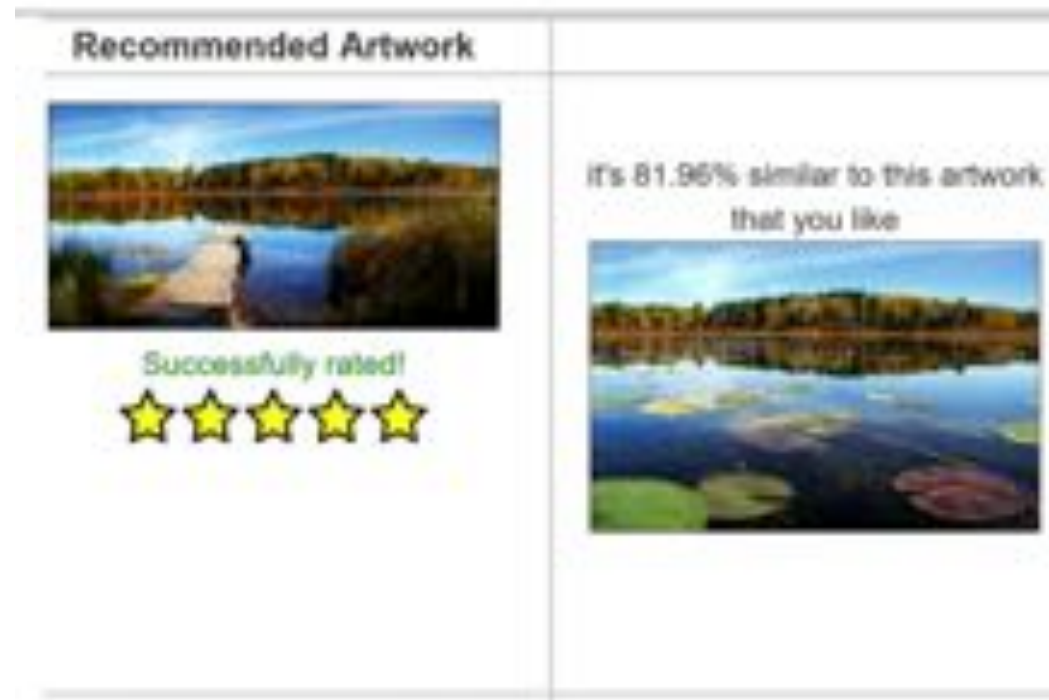
Filtrado colaborativo

- Los primeros sistemas recomendadores aparecen a comienzos de los 90's (Tapestry, e-mail XEROX)
- Noción principal de estos sistemas: **filtrado colaborativo**.



Filtrado basado en contenido

- El filtrado colaborativo funciona bien pero tiene el problema de *cold-start* y *new item*.
- Tenemos **el filtrado basado en contenido** como alternativa.

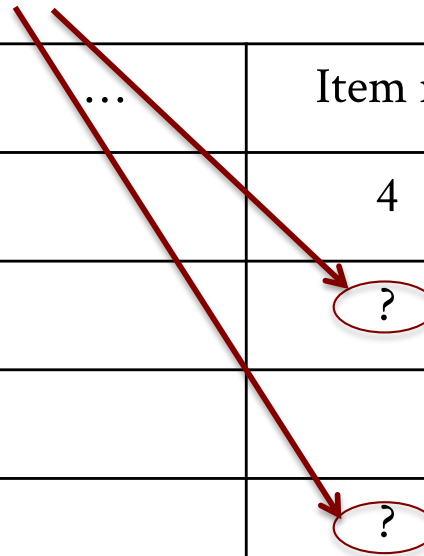


El Problema de Recomendación

- Hasta comienzos de la última década (1990-2011) en RecSys se usaba mucho la matriz de preferencias

¡Predecir!

	Item 1	Item 2	...	Item m
User 1	1	5		4
User 2	5	1		?
...				
User n	2	5		?



- ¿ Es buena la predicción?

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (\hat{r}_{ui} - r_{ui})^2}{n}}$$

Modelos latentes

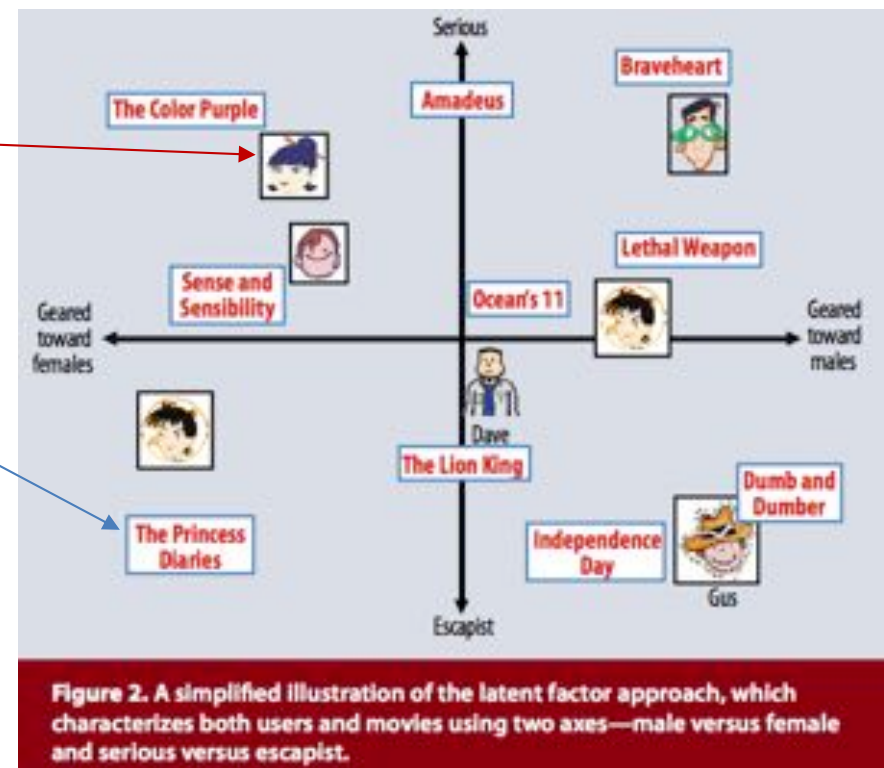
- A partir de la matriz de preferencias se derivan modelos de factores latentes para representar usuarios e ítems

$$\min_{q^*, p^*} \sum_{(u,i) \in K} (r_{ui} - q_i^T p_u)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

$$X = U \Sigma V^T$$

Diagram illustrating the matrix factorization equation $X = U \Sigma V^T$ with dimensions:

- X is an $N \times d$ matrix.
- U is an $N \times r$ matrix.
- Σ is an $r \times r$ matrix.
- V^T is an $r \times d$ matrix.



Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, 42(8), 30-37.

Un poco de historia

- Competencias en línea, como el Netflix prize (US\$ 1 millón), ayudaron a aumentar la atención de investigadores en el tema (2006-2009).

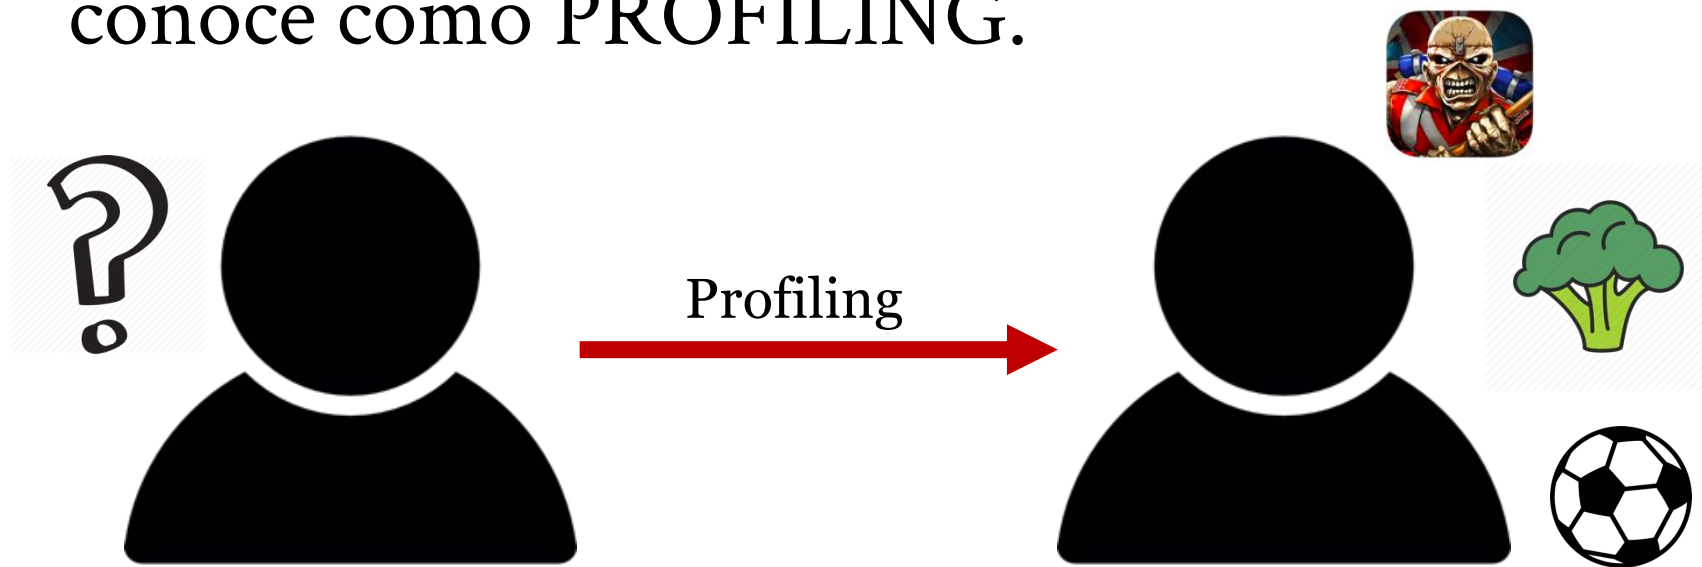


The screenshot shows the Netflix Prize Leaderboard website. At the top, there is a yellow banner with the text "Netflix Prize" and a red stamp that says "COMPLETED". Below the banner, there is a navigation bar with links: Home, Rules, Leaderboard, and Update. The main heading is "Leaderboard". Below this, it says "Showing Test Score: [Click here to show test score](#)". There is a dropdown menu for "Display top" with "20" selected and a "leaders" button. Below this is a table with the following columns: Rank, Team Name, Best Test Score, % Improvement, and Best Submit Time. The table lists the top three teams.

Rank	Team Name	Best Test Score	% Improvement	Best Submit Time
1	PrizeTeam	0.8561	10.0%	2009-07-26 18:18:29
2	The Economist	0.8567	10.0%	2009-07-26 18:38:22
3	Grand Prix Team	0.8582	9.9%	2009-07-10 21:24:40

Un concepto importante: Perfilar

- Un aspecto crítico para hacer recomendaciones es hacer un perfil del usuario en cuanto a sus características y preferencias, lo que en inglés se conoce como PROFILING.



- Volveremos a este concepto al final de esta charla.

AI 2020...

- ¿Cómo funcionan los sistemas de recomendación en la actualidad?
- ¿Qué problemas persisten y cuáles están siendo resueltos?

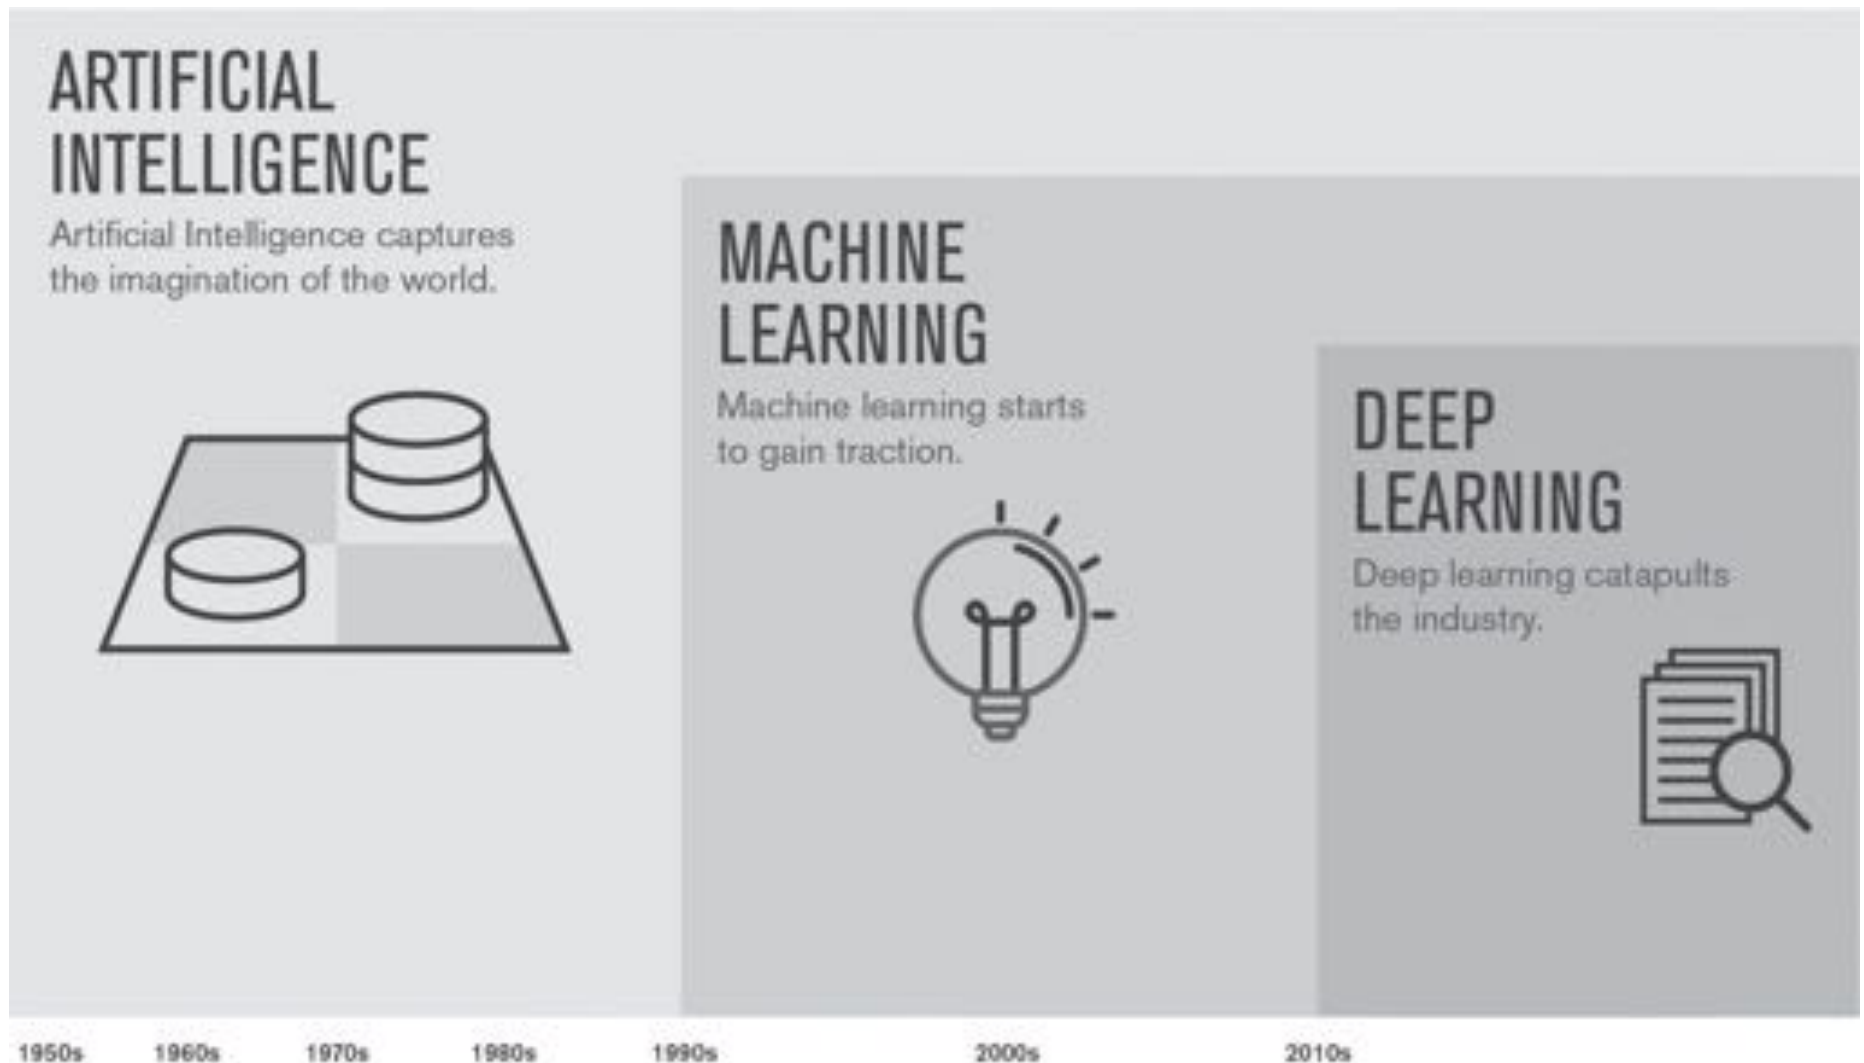
AI 2020...

- ¿Cómo funcionan los sistemas de recomendación en la actualidad?

AI 2020...


- ¿Cómo funcionan los sistemas de recomendación en la actualidad?
 - YouTube : Machine Learning -> Redes Neuronales
 - Netflix : No todo es redes neuronales
 - Spotify : Uso de contenido de canciones
- Mucho uso de reinforcement learning en la industria (multi-armed bandits)

AI, ML, Redes Neuronales (Profundas)



¿Qué es una red neuronal artificial?



- Es un modelo que permite aprender a hacer predicciones a partir de ejemplos de entrenamiento.



<https://mc.ai/aisaturdaylagos-the-torch-panther/>

¿Qué es una red neuronal artificial ?



- Modelo basada en redes de neuronas biológicas.



- 1943: McCulloch y Pitts "A Logical Calculus of the Ideas Immanent in Nervous Activity"

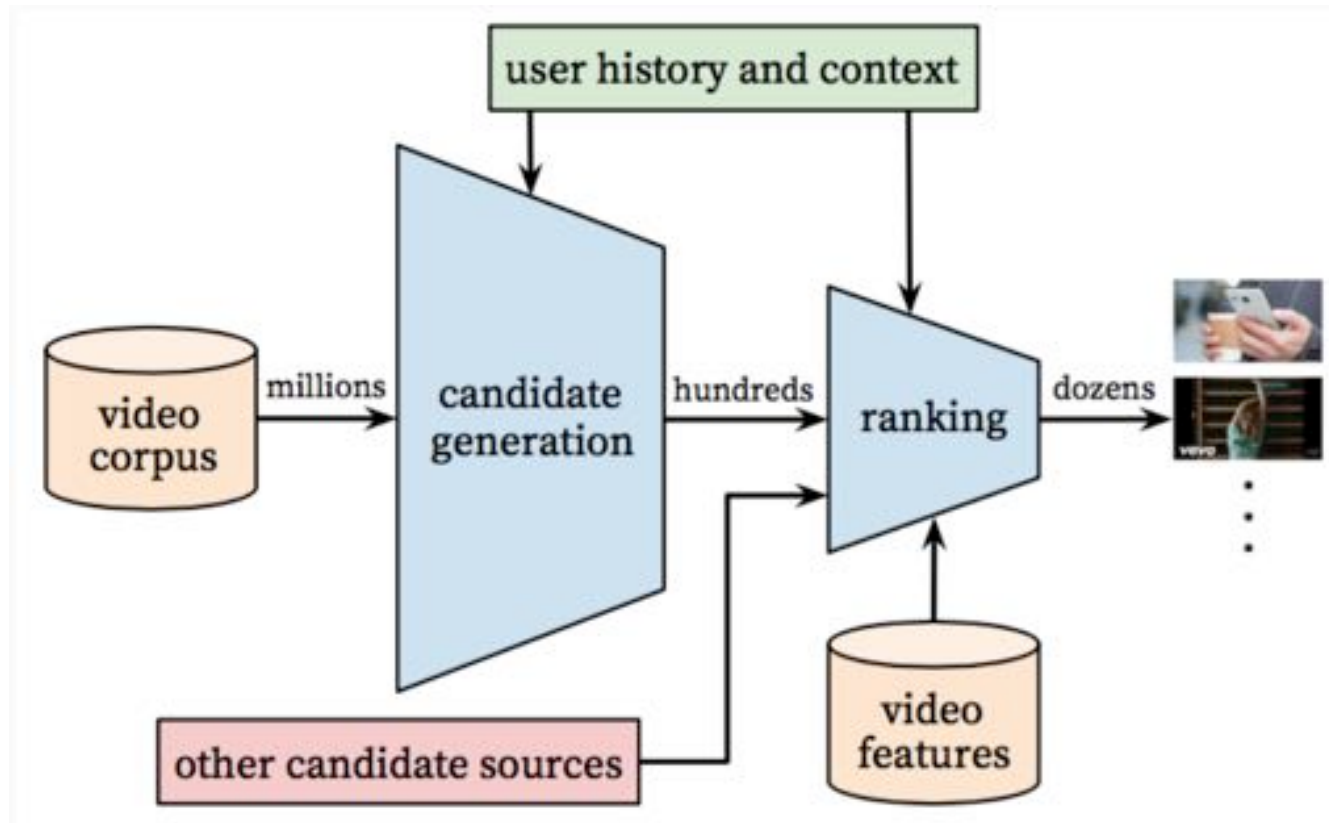
¿Qué es una red neuronal artificial?

- Una red neuronal artificial de muchas capas se le conoce como Red Neuronal Profunda



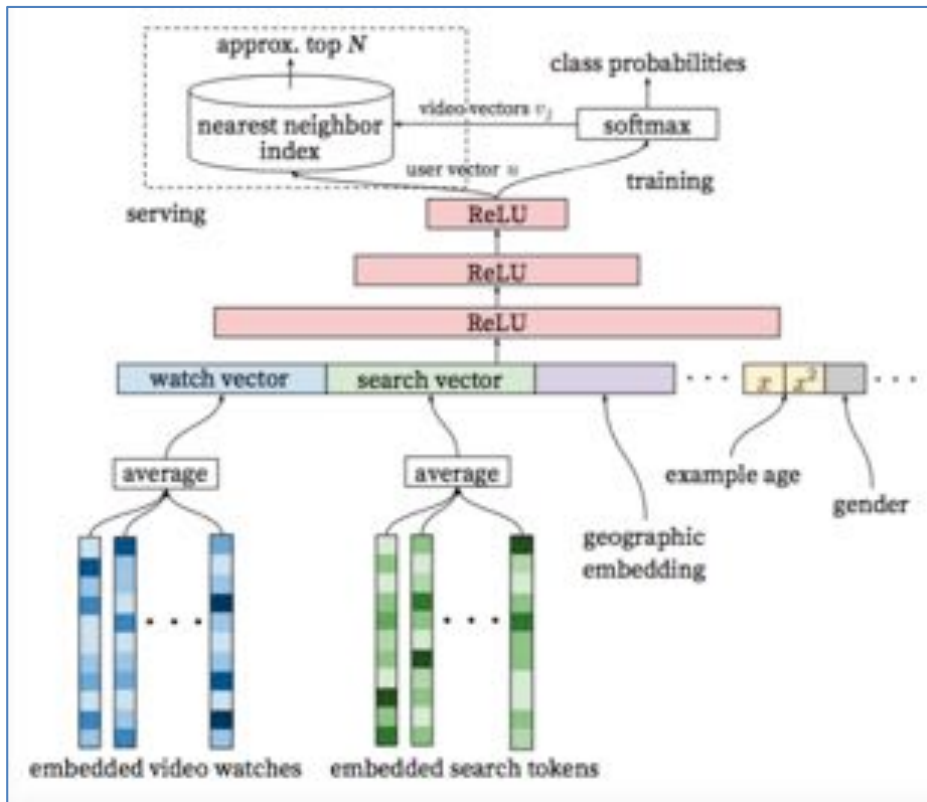
(Un) Sistema Recomendador de YouTube

- El Sistema Recomendador de YouTube (2016)

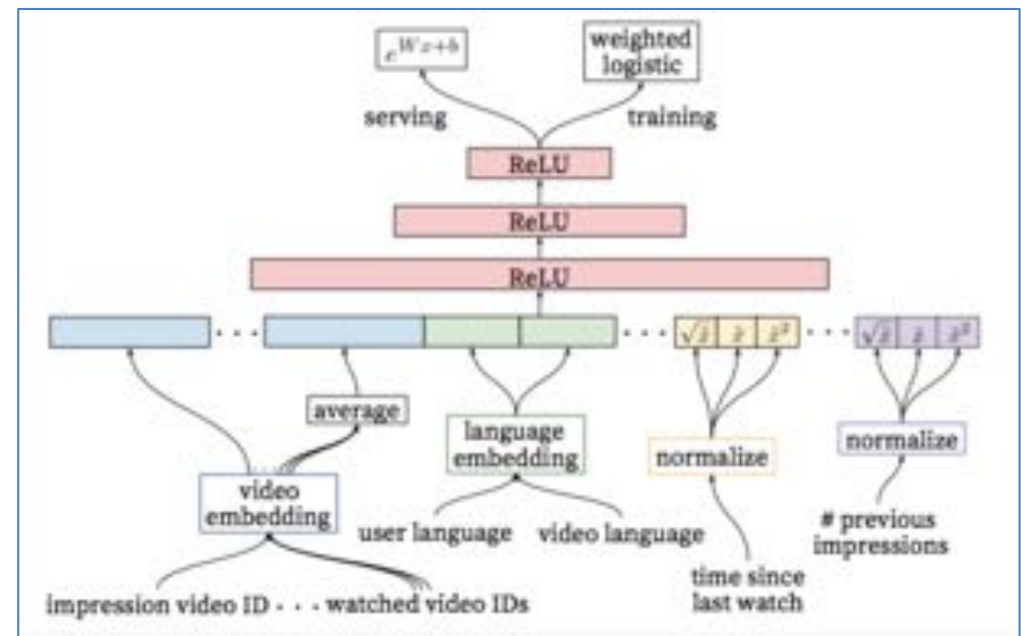


Covington, P., Adams, J., & Sargin, E. (2016). Deep neural networks for YouTube recommendations. In *Proceedings of the 10th ACM conference on recommender systems* (pp. 191-198). ACM.

Redes Neuronales en YouTube (2016-19)



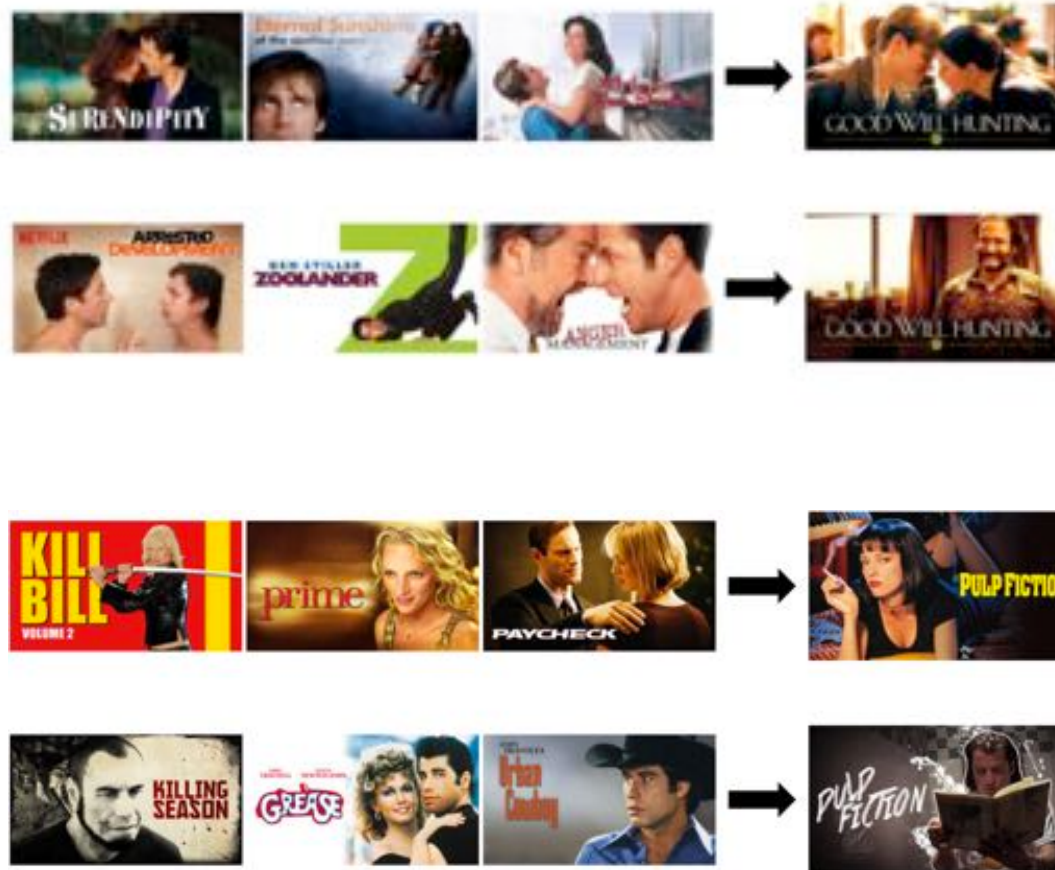
Generación de Candidatos



Ranking

Netflix: Recomendación de Artwork

- Técnica usada: Reinforcement learning



<https://medium.com/netflix-techblog/artwork-personalization-c589f074ad76>

Spotify

- Spotify combina varias técnicas:
 - Filtrado Colaborativo: Si a gente parecida a ti le gusta Pink Floyd, a ti te gustará Pink Floyd ...

Spotify


- Spotify combina varias técnicas:
 - Filtrado Colaborativo: Si a gente parecida a ti le gusta Pink Floyd, a ti te gustará Pink Floyd ...
 - Contenido: Spotify compró hace unos años EchoNest

<https://developer.spotify.com/documentation/web-api/reference/tracks/get-several-audio-features/>

```
{ "audio_features":  
  [ { "danceability": 0.808,  
      "energy": 0.626,  
      "key": 7,  
      "loudness": -12.733,  
      "mode": 1,  
      "speechiness": 0.168,  
      "acousticness": 0.00187,  
      "instrumentalness": 0.159,  
      "liveness": 0.376,  
      "valence": 0.369,  
      "tempo": 123.99,  
      "type": "audio_features",  
      "id": "4JpKVNYnVcJ8tuMKjAj50A",  
      "uri":  
        "spotify:track:4JpKVNYnVcJ8tuMKjAj50A",  
      "track_href":
```

Spotify

- Spotify combina varias técnicas:
 - Filtrado Colaborativo: Si a gente parecida a ti le gusta Pink Floyd, a ti te gustará Pink Floyd ...
 - Contenido: Spotify compró hace unos años EchoNest
 - Deep Learning



AI 2020...

10 Grandes Problemas en Sistemas de Recomendación

Problema #1

Filtros Burbuja (y cómo esto ayuda a la polarización)


The filter bubble ~ echo chamber

- Si bien para 2011 ya existía investigación en temas como diversidad, novedad, serendipia y transparencia en recomendaciones, el tema no había trascendido demasiado más allá de la academia.
- En 2011 Eli Pariser publica “The Filter Bubble: *What The Internet Is Hiding From You*”



Polarización en redes sociales

- La polarización en las redes sociales en línea es en parte efecto de la falta cuidado en considerar este aspecto en algoritmos de recomendación más allá de sólo optimizar ciertas métricas o KPI.



<https://gvrkiran.github.io/polarization/>

¿Solución?

- Problema más grande: ¿es la solución aumentar la exposición a contenido diverso con los algoritmos de recomendación?
 - Sesgos cognitivos evitan dar una respuesta clara (sesgo de confirmación)
 - “Quebrar el algoritmo” siguiendo contenido diverso no siempre resulta en contenido relevante.

Problema #2

La inteligencia artificial aún no es inteligente

¿Qué trata de aprender YouTube?

- Una IA no decide la tarea de aprendizaje: eso lo sigue entregando un ser humano.

¿Qué trata de aprender YouTube?

- Una IA no decide la tarea de aprendizaje: eso lo sigue entregando un ser humano
- En el caso de YouTube la tarea es: aprende a predecir el tiempo que un usuario pasará viendo un video, luego:
 - YouTube recomienda los videos que el usuario pasará viendo más tiempo

¿Qué trata de aprender YouTube?

- Una IA no decide la tarea de aprendizaje: eso lo sigue entregando un ser humano
- En el caso de YouTube la tarea es: aprende a predecir el tiempo que un usuario pasará viendo un video, luego:
 - YouTube recomienda los videos que el usuario pasará viendo más tiempo
- La IA no aprende a distinguir contenido bueno/malo (fake news, violencia, etc.)

Métricas != Objetivos

- Según Konstan (ACM Webinar) el objetivo de un recomendador no es llenar una matriz de ratings o predecir scores ... es encontrar y sugerir un conjunto de items que sean de utilidad para el usuario.
- Actualmente, no hay una métrica, función de pérdida o incentivo (para RL) que correlacione de forma perfecta con esta noción de maximizar la utilidad para el usuario.

Estudio sobre consumo de YouTube

Many Turn to YouTube for Children's Content, News, How-To Lessons

An analysis of videos suggested by the site's recommendation engine finds that users are directed toward progressively longer and more popular content

BY AARON SMITH, SKYE TOOR AND PATRICK VAN KESSEL



(MaaHoo Studio/Getty Images)


<https://www.pewinternet.org/2018/11/07/many-turn-to-youtube-for-childrens-content-news-how-to-lessons>

¿Mira la gente recomendaciones?

- Estudio de Pew Research Center

Majority of YouTube users across a wide range of age groups watch recommended videos

% of U.S. adults who use YouTube who say they watch the recommended videos that appear alongside the video they are currently watching ...



Metodología (Pew Research Internet)

How the Center conducted the 'random walks' analysis used in this report

Select a video at random from a list of 14,509 popular YouTube channels using the public YouTube API. This is the initial **starting video**.



Randomly select one of that video's top five **recommended videos** as listed in the API at the time.



Continue to randomly select recommended videos ...



... Until a total of five videos have been collected (the starting video plus four recommended videos).

"Many Turn to YouTube for Children's Content, News, How-To Lessons"

PEW RESEARCH CENTER

174,117 random walks resulted in

696,468 total encounters with


346,086 unique recommended videos

¿Hay diferencias en términos de largo?

- Estudio de Pew Research Center

YouTube recommendations point users to progressively longer content

Average video length (min:sec)



Source: Analysis of recommended videos collected via 174,117 five-step "random walks" beginning with videos posted to English-language YouTube channels with at least 250,000 subscribers, performed using the public YouTube API. Data collection performed July 18-Aug. 29, 2018.

"Many Turn to YouTube for Children's Content, News, How-To Lessons"


PEW RESEARCH CENTER

¿y Contenido más popular?

- Estudio de Pew Research Center

YouTube recommendations point to more popular content – regardless of starting criterion

*Average number
of views*



Problema #3

Falta de control y transparencia para el usuario

Recomendador tradicional

MovieLens

Page 1 of 1422 1 2 3 4 ... 1422 next Skip to page #: Go

Prediction or Rating ↕	Your Rating	Movie Information	Wish List
★★★★★	5.0 stars ▾	Pink Floyd: The Wall (1982) DVD info imdb flag Movie Tuner  Drama, Musical [add tag] Popular tags: social commentary  cult film  surreal 	<input type="checkbox"/>
★★★★☆	4.5 stars ▾	Lives of Others, The (Das leben der Anderen) (2006) DVD info imdb flag Movie Tuner  Drama, Romance, Thriller - German [add tag] Popular tags: disturbing  psychology  romance 	<input type="checkbox"/>
★★★★☆	Not seen ▾	Shawshank Redemption, The (1994) DVD info imdb flag Movie Tuner  Crime, Drama [add tag] Popular tags: based on a book  psychology  twist ending 	<input type="checkbox"/>
★★★★☆	Not seen ▾	Godfather, The (1972) DVD info imdb flag Movie Tuner  Crime, Drama - English, Italian [add tag] Popular tags: organized crime  based on a book  Oscar (Best Picture) 	<input type="checkbox"/>
★★★★☆	Not seen ▾	One Flew Over the Cuckoo's Nest (1975) DVD info imdb flag Movie Tuner  Drama [add tag] Popular tags: psychology  based on a book  Oscar (Best Picture) 	<input type="checkbox"/>
★★★★☆	Not seen ▾	Usual Suspects, The (1995) DVD info imdb flag Movie Tuner  Crime, Mystery, Thriller - English, Hungarian, Spanish, French [add tag] Popular tags: organized crime  twist ending  Kevin Spacey 	<input type="checkbox"/>


Explicaciones y Control al Usuario

GoodReads: Book recommender system

Here are some book recommendations...

Recommendations of books

Your interest in **Classics** updated: 1 minute ago



Each book has a 'want to read' button and a star rating (5 stars) with a 'Not interested' link below it.

Options of User Control

Recommendations by Shelf


Overview

read 50

Tip: Create a new bookshelf of related books that you've enjoyed or want to read. You'll get recommendations based on those books!

Explainability

Your interest in **Contemporary** updated: 1 minute ago



Each book has a 'want to read' button and a star rating (5 stars) with a 'Not interested' link below it.

More Actions

- Recommendations from Users
- Give Recommendations
- Ask for Recommendations
- Books Marked as 'Not interested'

BRAIN TRAINING GAMES
Improve your memory

¿qué opciones de control se pueden dar?

- Desde ... “no quiero ver este contenido o tipo de publicidad/contenido”

hasta

- Déjame modificar mi perfil u opciones en el algoritmo de recomendación.

Visualización

- Varios grupos (entre los que incluyo nuestro trabajo) estudian cómo utilizar visualizaciones interactivas:

He, C., Parra, D., & Verbert, K. (2016). Interactive recommender systems: A survey of the state of the art and future research challenges and opportunities. *Expert Systems with Applications*, 56, 9-27.

SetFusion

Tune weights of the recommender methods: (b)

Most bookmarked papers: 0.4

Similar to your favorite articles: 0.8

Frequently cited authors in ACM DL: 0.4

Update Recommendation List →

* Hover over circles to explore articles
* Click on the diagram to highlight subsets (c)

Articles in top30 (green dot)
Articles not in top30 (yellow dot)

Similar to your favorite articles

Most bookmarked papers

**2. Can't see the forest for the trees?
A citation recommendation system**

(a)

2. Can't see the forest for the trees? A citation recommendation system
by C. Lee Giles, Cornelia Caragea, Adrian Silvescu, Prasenjit Mitra [\[see abstract\]](#)

3. When thumbnails are and are not enough: Factors behind users
by Dan Albertson [\[see abstract\]](#)

7. Gendered Artifacts and User Agency
by Andrea R. Marshall, Jennifer A. Rode [\[see abstract\]](#)

8. Two Paths to Motivation through Game Design Elements: Reward-Based Gamification and Meaningful Gamification
by Scott Nicholson [\[see abstract\]](#)

9. Automatic Identifying Search Tactic in Individual Information Seeking: A Hidden Markov Model Approach
by Zhen Yue, Shuguang Han, Daqing He [\[see abstract\]](#)

11. Old Maps and Open Data Networks
by Werner Robitza, Carl Lagoze, Bernhard Haslhofer, Keith Newman, Amanda Stefanik [\[see abstract\]](#)

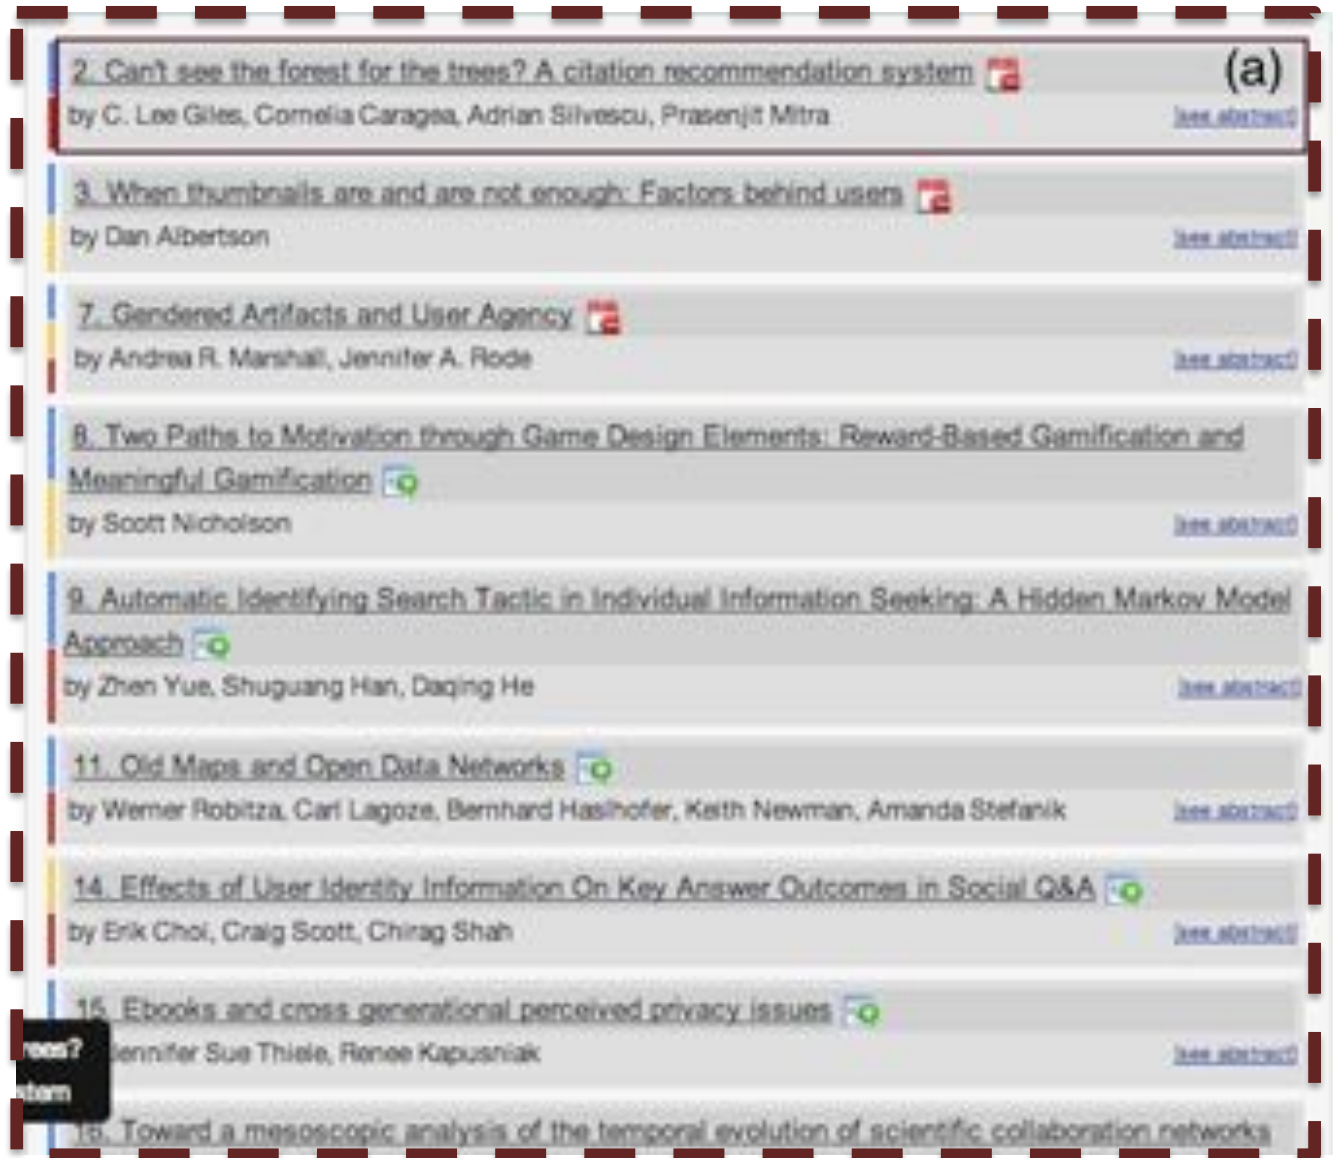
14. Effects of User Identity Information On Key Answer Outcomes in Social Q&A
by Erik Choi, Craig Scott, Chirag Shah [\[see abstract\]](#)

15. Ebooks and cross generational perceived privacy issues
Jennifer Sue Thiele, Renee Kapusniak [\[see abstract\]](#)

16. Toward a mesoscopic analysis of the temporal evolution of scientific collaboration networks

SetFusion

Lista rankeada
tradicional



The image shows a screenshot of a ranked list of research papers, likely from a conference or journal. The list is enclosed in a dashed red border. Each entry consists of a rank number, a title, authors, and a link to the abstract. The papers are ranked from 2 to 16. The first entry is highlighted with a red background. The second entry has a blue background. The third entry has a yellow background. The fourth entry has a blue background. The fifth entry has a blue background. The sixth entry has a blue background. The seventh entry has a blue background. The eighth entry has a blue background. The ninth entry has a blue background. The tenth entry has a blue background. The eleventh entry has a blue background. The twelfth entry has a blue background. The thirteenth entry has a blue background. The fourteenth entry has a blue background. The fifteenth entry has a blue background. The sixteenth entry has a blue background. The list is titled '(a)' in the top right corner. The papers are as follows:

Rank	Title	Authors	Link
2	Can't see the forest for the trees? A citation recommendation system	by C. Lee Giles, Cornelia Caragea, Adrian Silvescu, Prasenjit Mitra	[see abstract]
3	When thumbnails are and are not enough: Factors behind users	by Dan Albertson	[see abstract]
7	Gendered Artifacts and User Agency	by Andrea R. Marshall, Jennifer A. Rode	[see abstract]
8	Two Paths to Motivation through Game Design Elements: Reward-Based Gamification and Meaningful Gamification	by Scott Nicholson	[see abstract]
9	Automatic Identifying Search Tactic in Individual Information Seeking: A Hidden Markov Model Approach	by Zhen Yue, Shuguang Han, Daqing He	[see abstract]
11	Old Maps and Open Data Networks	by Werner Robitza, Carl Lagoze, Bernhard Haslhofer, Keith Newman, Amanda Stefanik	[see abstract]
14	Effects of User Identity Information On Key Answer Outcomes in Social Q&A	by Erik Choi, Craig Scott, Chirag Shah	[see abstract]
15	Ebooks and cross generational perceived privacy issues	by Jennifer Sue Thiele, Renee Kapusniak	[see abstract]
16	Toward a mesoscopic analysis of the temporal evolution of scientific collaboration networks		

SetFusion

Sliders

Controlar importancia de cada algoritmo de recomendación.




Diagrama de Venn Interactivo

Filtrar items e inspeccionar recomendaciones.

Contrafactuales

- Darle al usuario la opción de inspeccionar escenarios “¿si es que hubiera hecho like en X, qué me habrías recomendado?”



Alice: Why did I receive this recommendation "Jack Wolfskin backpack"?

PRINCE: You **bought** "Adidas Hiking Shoes";
You **reviewed** "Nikon Coolpix Camera" with "Sleek! Handy on hikes!";
You **rated** "Intenso Travel Power Bank" highly.

If you **had not** done these actions:
"iPad Air" **would have replaced** "Jack Wolfskin backpack".

Ghazimatin, A., Balalau, O., Saha Roy, R., & Weikum, G. (2020). PRINCE: Provider-side Interpretability with Counterfactual Explanations in Recommender Systems. In *Proceedings of the 13th International Conference on Web Search and Data Mining* (pp. 196-204).

Problema #4

¿Son las recomendaciones “Justas”?

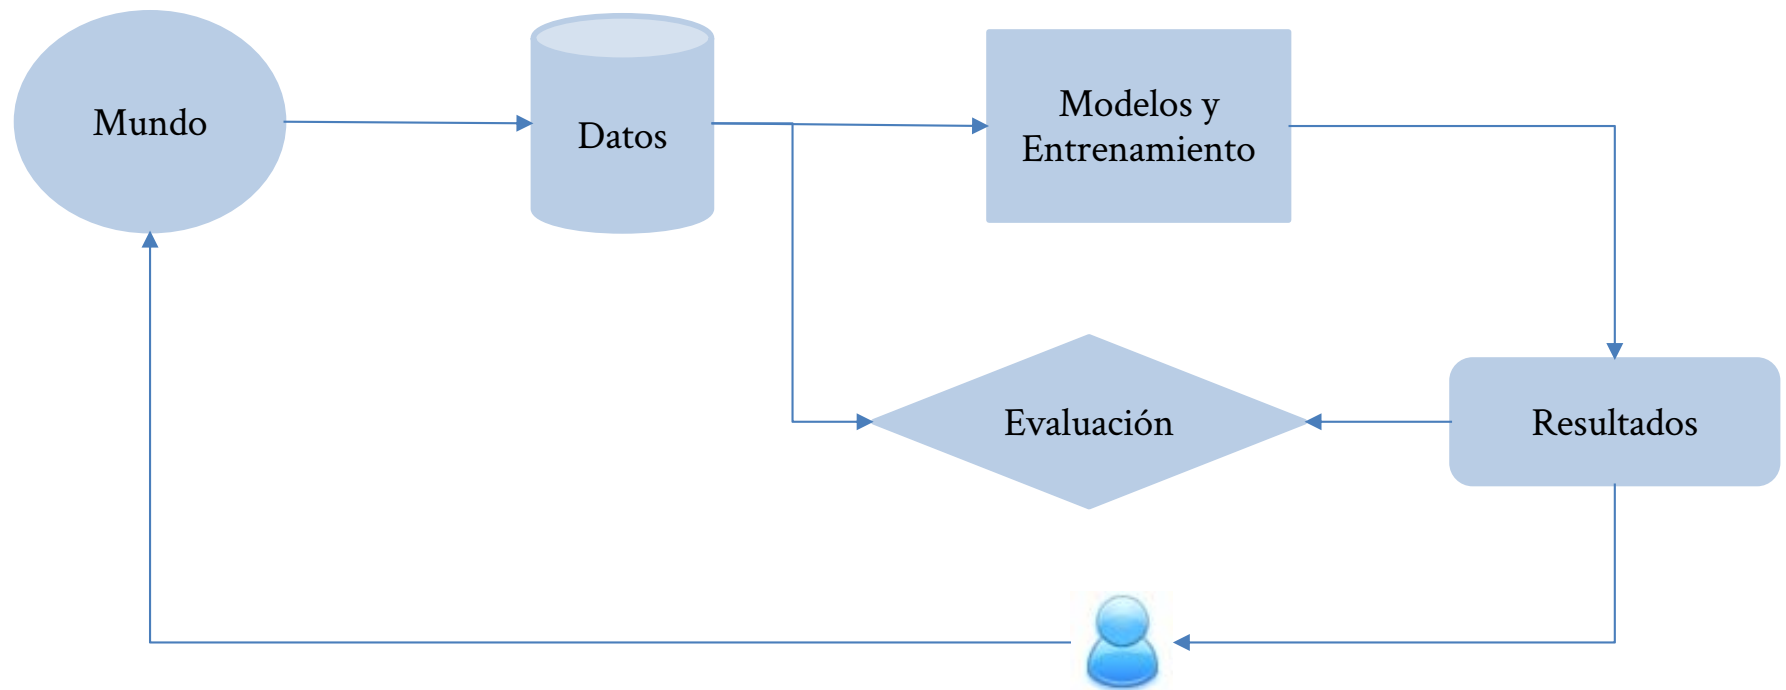
(fair)

- No siempre, pero hay que definir, cuantificar y estudiar el problema para abordarlo.

JET IA / FAT AI

- Justo (no sesgado, ecuánime)
- Explicable (responsable de decisiones)
- Transparente (a qué nivel? Interpretable)
- Fairness
- Accountability
- Transparency

Origen del Sesgo en RecSys



From tutorial by Diaz, Ekstrand & Burke (SIGIR and RecSys 2019): <https://fair-ia.ekstrandom.net/sigir2019>

Sesgo en los datos




Figure 5: Words most associated with women (left) and men (right), estimated with *Pointwise Mutual Information*. Font size is inversely proportional to PMI rank. Color encodes frequency (the darker, the more frequent).

Wagner, C., Graells-Garrido, E., Garcia, D., & Menczer, F. (2016). Women through the glass ceiling: gender asymmetries in Wikipedia. *EPJ Data Science*, 5(1), 5.

Sesgo de consumidor y productor

- La figura, de Ekstrand, Diaz, Burke (2019) muestra los usuarios de *Information Access Systems*



From tutorial by Diaz, Ekstrand & Burke (SIGIR and RecSys 2019): <https://fair-ia.ekstrandom.net/sigir2019>

Consumer Bias in RecSys

All The Cool Kids, How Do They Fit In?
Popularity and Demographic Biases in Recommender
Evaluation and Effectiveness^{*†}

Michael D. Ekstrand

MICHAELEKSTRAND@BOISESTATE.EDU

Mucun Tian

MUCUNTIAN@U.BOISESTATE.EDU

Ion Madrazo Azpiazu

IONMADRAZO@U.BOISESTATE.EDU

Jennifer D. Ekstrand

JENNIFEREKSTRAND@U.BOISESTATE.EDU

Oghenemaro Anuyah

OGHENEMAROANUYAH@U.BOISESTATE.EDU

David McNeill

DAVIDMCNEILL@U.BOISESTATE.EDU

Maria Soledad Pera

SOLEPERA@BOISESTATE.EDU

People and Information Research Team, Dept. of Computer Science, Boise State University

Desafíos para RecSys Justos

- **Datos:** La mayoría de los datasets no tienen información para cuantificar sesgo, es un problema abierto.
- **No hay solución única:** ¿Qué representa al mundo de forma objetiva y única? ¿Qué representa al mundo como debería o podría ser?
- Deberíamos considerar **sesgos tanto de consumidor como de productores** de contenido: recomendar por popularidad es fácil y efectivo, pero no promovemos creación de nuevo y mejor contenido.

Transparencia: El Caso de YouTube

- Guillaume Chaslot
- Trabajó en el desarrollo del primer recomendador de videos de YouTube.

How an ex-YouTube insider investigated its secret algorithm



El Caso de YouTube

- Guillaume Chaslot
- Al renunciar a YouTube, creó un Sistema para estimar qué cosas recomienda YouTube (que podrían ser nocivas)
- <https://www.theguardian.com/technology/2018/feb/02/youtube-algorithm-election-clinton-trump-guillaume-chaslot>

How an ex-YouTube insider investigated its secret algorithm



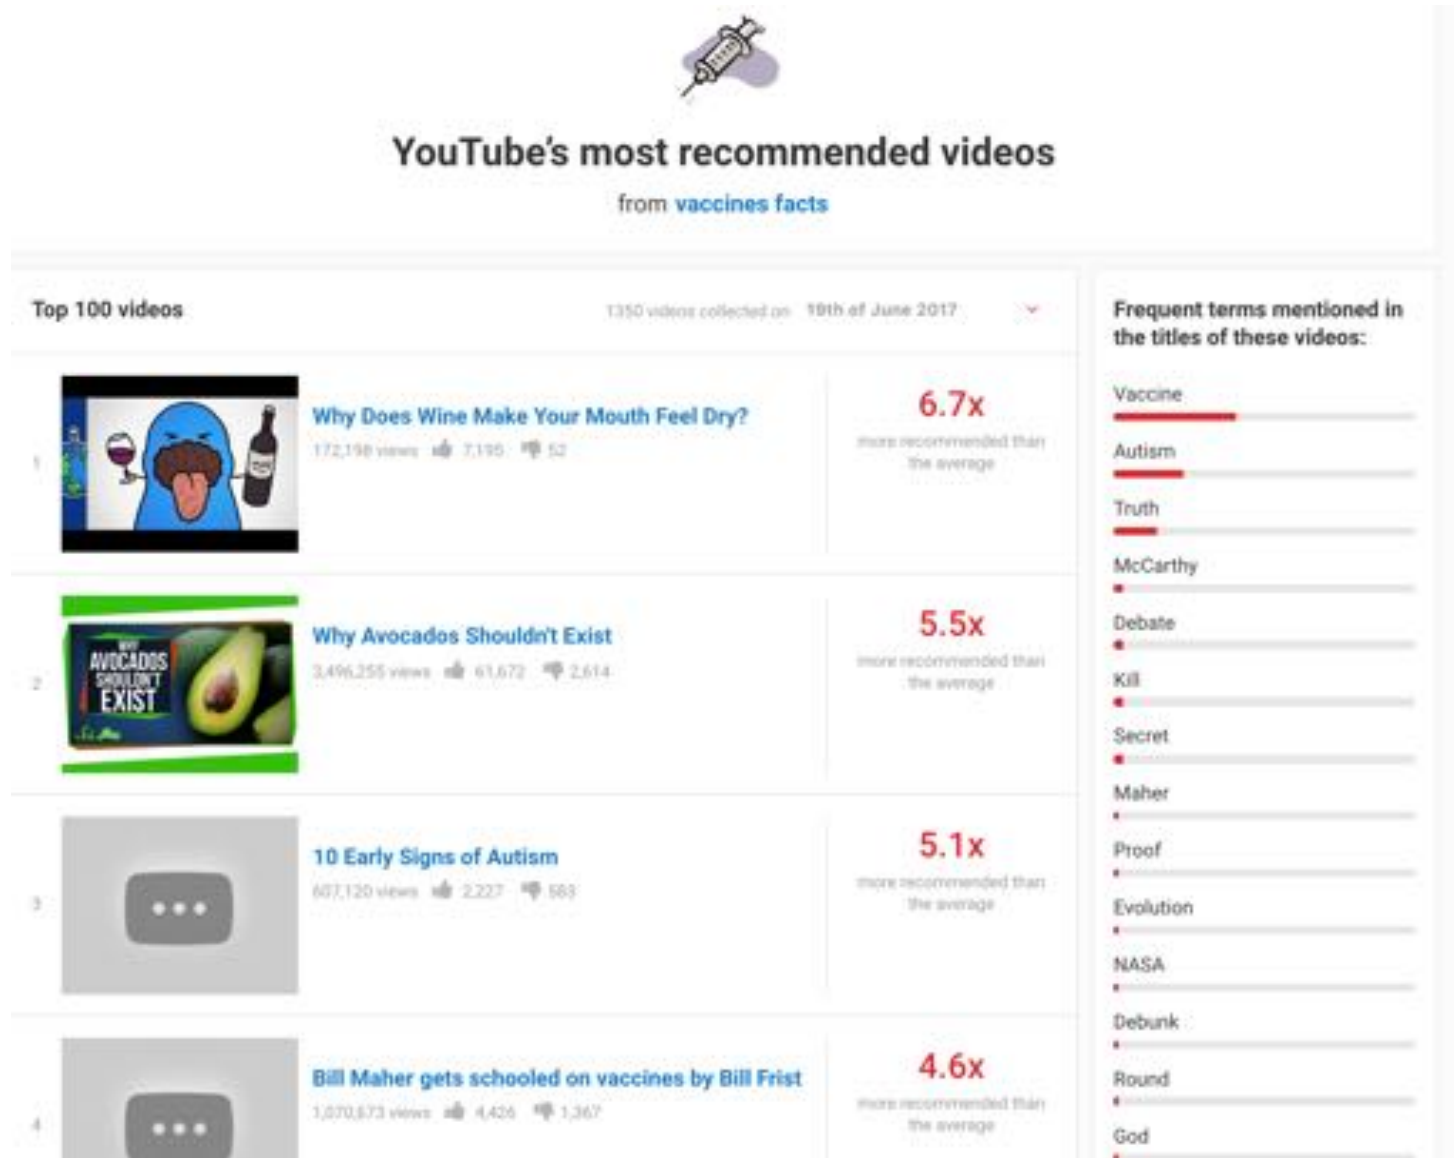
<https://algotransparency.org>

We created a robot to find out

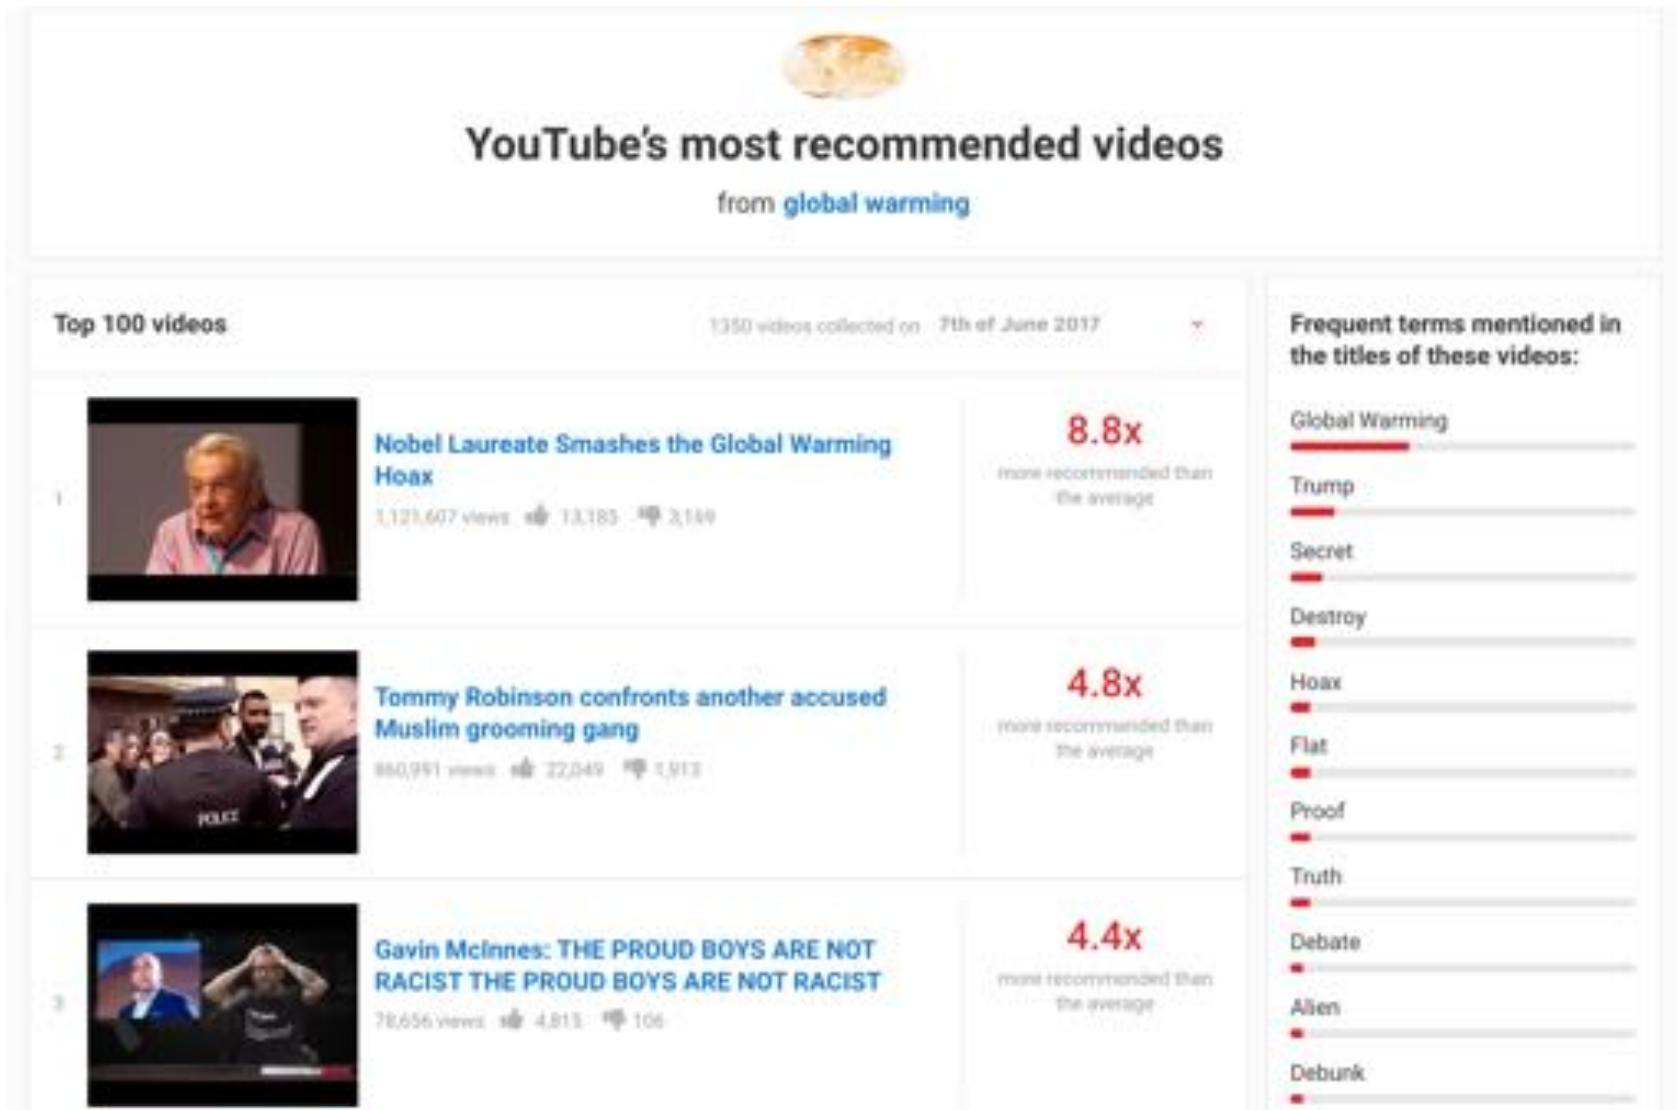
Using search terms, our robot crawls all the top recommended videos and keeps track of the ones which are recommended most often.



<https://algotransparency.org>



<https://algotransparency.org>




Problema #5

Métricas

Netflix Prize

- Joe Konstan << terminado el Netflix prize, se vio que mejoras en décimas o centésimas del error de predicción no necesariamente se relacionaban con una mejor experiencia del usuario >>



Academia vs. industria vs. utilidad

Métricas de error y ranking

- RMSE, MAE
- Top-N ranking metrics

Business KPIs

- CTR
- Conversion rates
- Sales increase
- Engagement

Utilidad para el usuario

- Diversidad
- Novedad
- **Serendipia**
- Objetivos de vida

Comentarios

- [Tao Ye] ¿Cómo vincular fácilmente los objetivos comerciales (por ejemplo, más usuarios que regresan, duración de las sesiones) con las métricas de un recsys?
- [Tao Ye] ¿debería uno siempre optimizar todo lo que pueda? ¿Qué margen de ética debe establecer una empresa para equilibrar la ética con los KPI del negocio?

Comentarios

- [Pablo Castells] Veo que los desafíos de la evaluación off-line (procedimientos, dimensiones, sesgos, conjuntos de datos y recursos, etc.) siguen siendo relevantes y también clave para ayudar a que la investigación académica sea relevante para la industria.
- [Pablo Castells] También relacionado con esto, la perspectiva de recomendación **como un proceso cíclico** pueden ser una dirección importante que necesita más trabajo y reflexión (¿relacionado con arreglar Netflix?)

Problema #6

Interactividad y múltiples fuentes de datos

Interactividad

- Ya el 2013, Amatriain indicaba la importancia de considerar distintos escenarios de interacción para recomendaciones.



Amatriain, X. (2013). Mining large streams of user data for personalized recommendations. ACM SIGKDD Explorations Newsletter, 14(2), 37-48.

RecSys Conversacionales y Multimodales

- [Tao Ye] ¿cuál es la mejor manera de diseñar recsys multimodales? Speech + pantalla pequeña, speech+ pantalla grande ¿Los principios se aplican exactamente de la misma manera? Speech solo es complejo!



Problema #7

Reproducibilidad de los resultados de investigación

Reproducibilidad en Ciencia

- El problema de reproducibilidad en ciencia en general también ocurre en RecSys.
- A pesar de ser una comunidad cercana a IA/ML que es normalmente muy abierta (Código, pre-prints) no siempre se comparte código, experimentos, etc.

Reproducibilidad en Ciencia

- El best paper de RecSys 2019 mostró que algunos algoritmos de deep learning no generalizaban bien en otros datasets o perdían contra métodos baseline muy antiguos!

Table 6: Experimental results for NCF.

	Pinterest			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.1663	0.1065	0.2744	0.1412
UserKNN	0.7001	0.5033	0.8610	0.5557
ItemKNN	0.7100	0.5092	0.8744	0.5629
P ³ _{tr}	0.7008	0.5018	0.8667	0.5559
RP ³ _{β}	0.7105	0.5116	0.8740	0.5650
NeuMF	0.7024	0.4983	0.8719	0.5536

[Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches](#)

by M. Ferrari Dacrema, P. Cremonesi, D. Jannach

Reproducibilidad en Ciencia

- (comentario personal: el título del paper es un poco hype)

Table 6: Experimental results for NCF.

	Pinterest			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.1663	0.1065	0.2744	0.1412
UserKNN	0.7001	0.5033	0.8610	0.5557
ItemKNN	0.7100	0.5092	0.8744	0.5629
$P^{\frac{3}{2}}$	0.7008	0.5018	0.8667	0.5559
$RP^{\frac{3}{2}}$	0.7105	0.5116	0.8740	0.5650
NeuMF	0.7024	0.4983	0.8719	0.5536

[Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches](#)

by M. Ferrari Dacrema, P. Cremonesi, D. Jannach

Gran aporte de Redes Neuronales

- Han facilitado en gran medida incorporar de forma relativamente fácil diferentes contextos y fuentes de datos para hacer modelos más cohesionados.

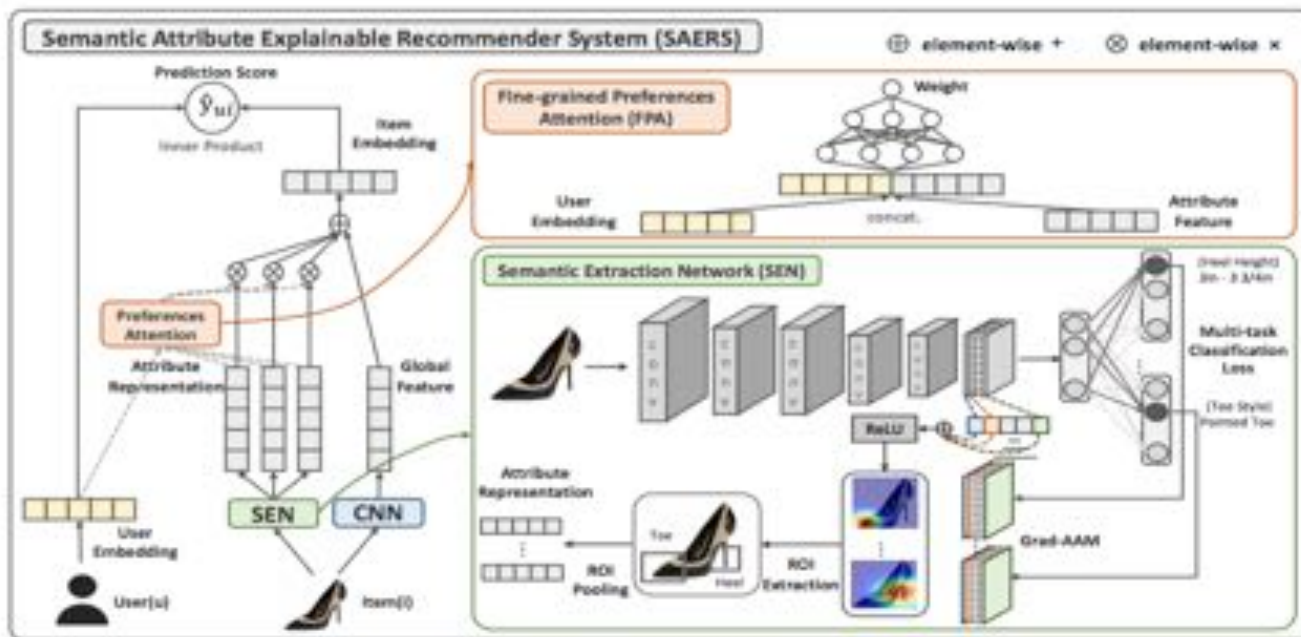


Figure 3: The architecture for Semantic Attribute Explainable Recommender System (SAERS)

Hou, M., Wu, L., Chen, E., Li, Z., Zheng, V. W., & Liu, Q. (2019). Explainable fashion recommendation: a semantic attribute region guided approach. In *Proceedings of the 28th International Joint Conference on Artificial Intelligence* (pp. 4681-4688). AAAI Press.

¿Solución a reproducibilidad?

- Por primer año, ACM RecSys 2020 tiene un reproducibility track.
- Hay un gran espacio de investigación para hacer mejores benchmark más allá de los datasets movielens, lastfm y citeulike (muy usados en la literatura de RecSys)

Problema #8

Conductismo

(Draft)



¿Somos y seremos lo que consumimos?

- El paper "Behaviorism is Not Enough: Better Recommendations through Listening to Users" da luces sobre un problema de RecSys

Neil Hunt en RecSys 2014: << "... *su métrica (usuarios que miran películas) no pueden distinguir entre un usuario que obtiene valor del servicio y la adicción*". >>

Tu asistente personal

- [Marko Tkalcic]
Los sistemas de recomendación pasaron de los mini algoritmos de terminación matricial a sistemas que impactan la vida de los usuarios



Tu asistente personal

- [Marko Tkalčic] Por ejemplo, el **cambio de comportamiento asistido por un recomendador** requiere algoritmos para predecir no lo que los usuarios eligen o hacen ahora, deducible de los datos de comportamiento, sino **lo que deberían elegir o hacer en el futuro para estar más saludables, en forma, más sostenibles o culturalmente conscientes.**

Problema #9

RecSys para audiencias no tradicionales (TODO)

Comentario de colega

- [Soledad Pera, BSU, EEUU] Como comunidad hemos explorado usuario vs grupo; contexto; incluso hemos segmentado grupos de usuarios (por edad, ubicación). Pero, ¿qué hay de echar un vistazo más profundo a cómo el diseño y la evaluación de los sistemas de recomendación podrían no estar a la altura de las expectativas o no servir a audiencias como niños, personas que no hablan inglés como su primer idioma, personas afectadas por trastornos de salud mental?

Problema #10

Privacidad en RecSys

(TODO)

El caso Facebook

- <https://labs.rs/en/quantified-lives/>
- *En Manufacturing Consent*, Herman and Chomsky

<< El objetivo de un periódico no es producir y vender contenido, sino que producir una audiencia para vender publicidad >>

La Fábrica Algorítmica de Facebook



- Recolección De Datos

<https://labs.rs/en/facebook-algorithmic-factory-immaterial-labour-and-data-harvesting/>

- Almacenamiento y procesamiento algorítmico

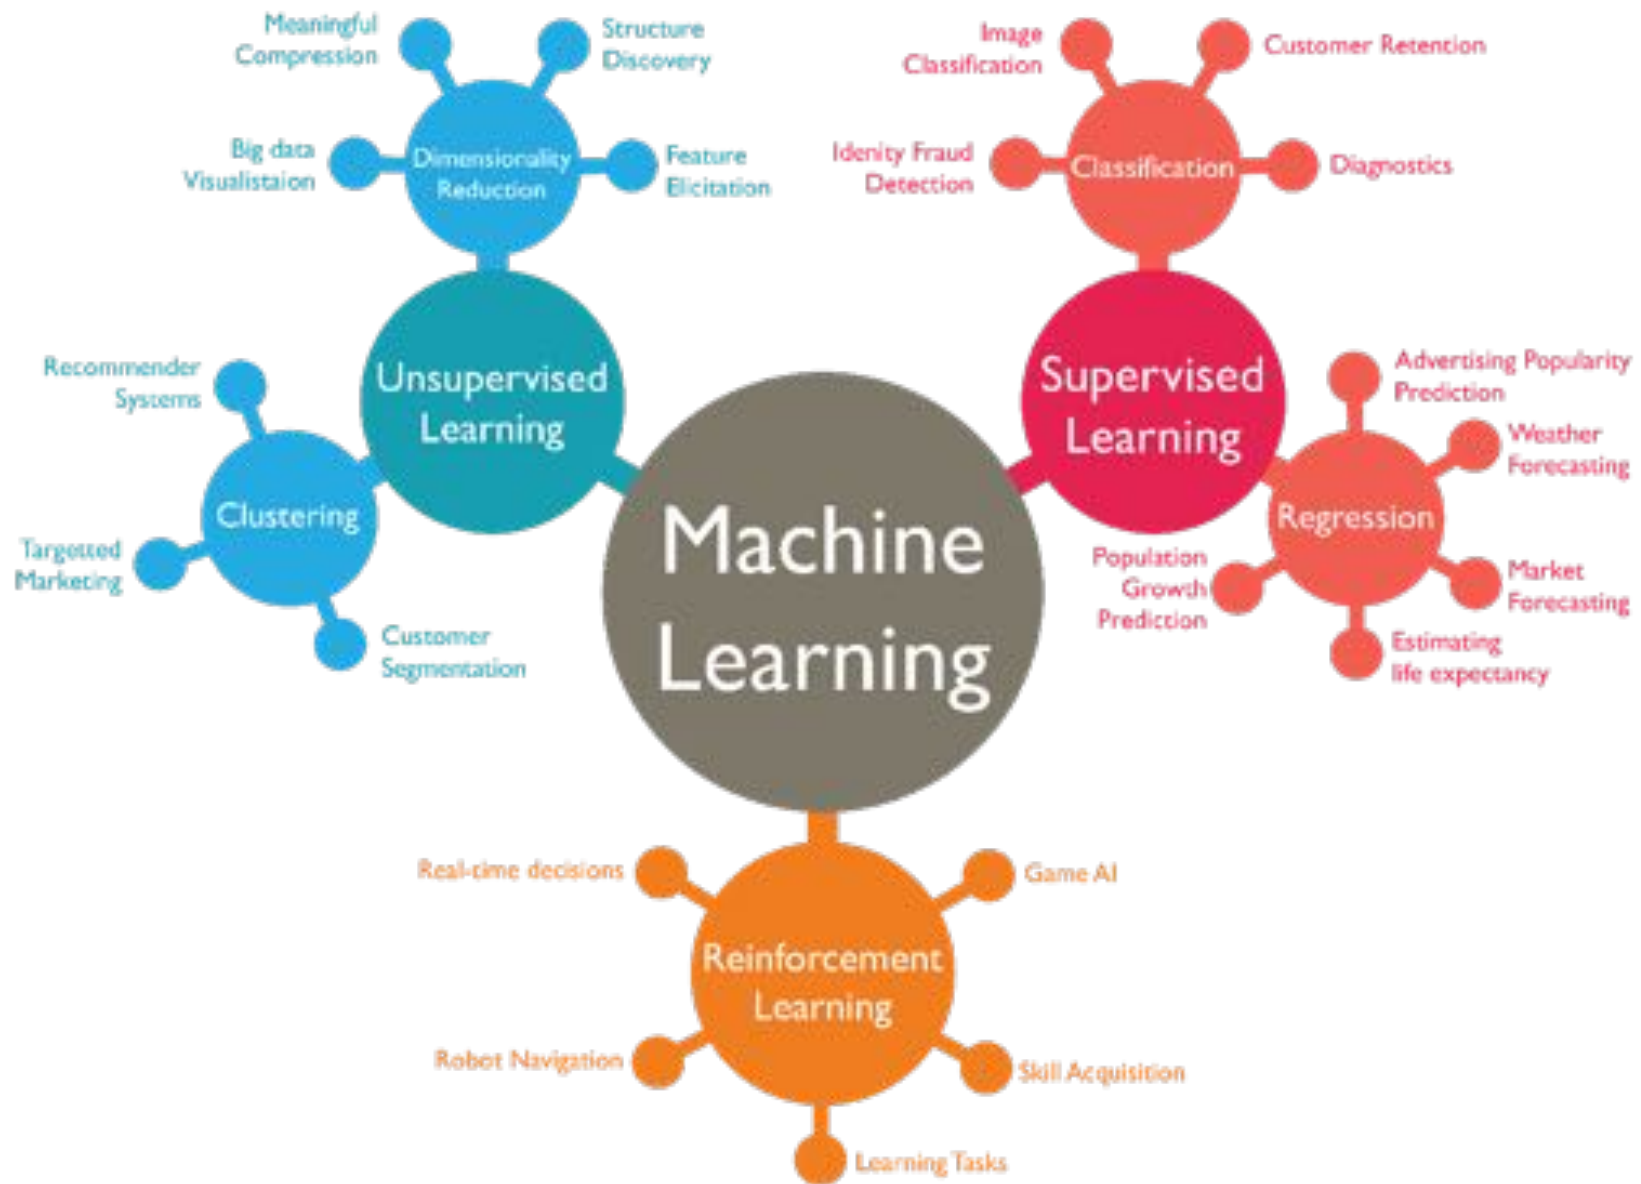
<https://labs.rs/en/facebook-algorithmic-factory-human-data-banks-and-algorithmic-labour/>

- Apuntar a los perfiles

<https://labs.rs/en/quantified-lives/>

Cierre y Discusión

- dparra@ing.puc.cl
- <http://dparra.sitios.ing.uc.cl/>



IA Lab UC <http://ialab.ing.puc.cl/>



Grupo SocVis



The PUC SocVis (Social Computing & Visualization Group) studies issues related with



Online Social Networks



Recomender systems



Visual Analytics